


Development of a Generative AI- Based Analytics Tool for Supply Chain Process Optimization

Ablauf

- Hintergrund und Motivation
- Methodik
- Forschungsfrage 1
- Forschungsfrage 2
- Implikationen
 - MSD
 - Research
- Diskussion (30 min)
- Live Demo Open Beta



MSD AI Strategie



Hintergrund und Motivation

Modellversionen und Unterscheidungsmerkmale



GenAI Models



Model	Alpha Version	Open Beta	Insight Retriever
Datentypen	- Unstrukturierte Daten	- Unstrukturierte Daten - (Simulierte Strukturierte Daten)	- Unstrukturierte Daten - Strukturierte Daten
Teilprojekt	- Knowledge Management System	- Knowledge Management System	- Knowledge Management - Data GPTeal
Inhaltlicher Umfang	- Quality Documents (QDocs) (1 K)	- Quality Documents (QDocs) (3 K) - (Simulierte Strukturierte Daten)	- Quality Documents (QDocs) (5 K) - Strukturierte Daten aus SAP-Tabellen
Forschungsfragen	Forschungsfrage 1 & 2	Forschungsfrage 1 & 2	Forschungsfrage 2

Methodik

Iterative Modell Entwicklung | Qualitative Modell Evaluation

1

Iterative Modell Entwicklung



2

Qualitative Modell Evaluation

- **Strukturierten Fragebogen:**
Kombination aus Ratings und offenen **Kommentaren** zur Modellbewertung
- **Fachexperten als Teilnehmenden:**
Praxisnahe, selbst formulierte Fragen durch Supply Chain Experten
- **Definierte Bewertungskriterien:**
Verfügbarkeit, Reaktionszeit, Genauigkeit (Accuracy) und Zufriedenheit (Satisfaction)
- **Konsolidierte Zusammenfassung:**
Quantifizierung und **Analyse** der Ergebnisse in einer konsolidierten Excel Datei
- **Universal Einsetzbar:**
Am **Open Beta Model** durchgeführt, Methodik jedoch grundsätzlich auf andere Modelle anwendbar



Forschungsfrage 1

Forschungsfrage 1

Analyse Forschungsfrage


How can a GenAI- and RAG-based Knowledge Management System, built on a vector-based embedding approach within a development and collaboration platform like Dataiku, be optimized to integrate heterogeneous unstructured supply chain data, address graphical content interpretation limitations, and be evaluated through quantitative accuracy measures and qualitative user feedback to ensure context-aware decision support?

- Integration und Optimierung heterogener, unstrukturierter Supply Chain Daten (1)
- Umgang mit Einschränkungen bei der Interpretation grafischer Inhalte (2)
- Evaluation des Modeloutputs mittels quantitativer und qualitativer Methoden (3)

Integration unstrukturierter Supply Chain Daten (1/3)

Threading

Threading Optimierung (QDocs)



Identifikation eines Performance-Engpass:

- Sehr lange **Verarbeitungszeiten** bei umfangreichen QDocs-Dokumenten, aufgrund hoher Seitenzahlen
- QDocs Datenquellen: ~ 48 min / Datei
- Restliche Datenquellen: ~ 3 min / Datei

Parallelisierung des Prozesses:

- Reduktion der Verarbeitungszeiten, mithilfe Prozess Parallisierung, durch Einsatz von **Python Threading**

Optimale Thread-Konfiguration:

- Empirische Bestimmung von **50 Threads** als effizientester Konfiguration im Test Datensatz

Skalierbare Integration:

- Erfolgreiche **Weiterverarbeitung** grosser QDocs-Datenmengen durch **Batch-Verarbeitung**

Einschränkungen bei der Interpretation grafischer Inhalte (2/3)

Lösungsansätze

Einsatz alternativer LLMs

LLM-Auswahl:

- Einsatz leistungstärkeren LLMs desselben Anbieters mit besseren Fähigkeiten zur Extraktion

Grafikspezialisierte LLMs:

- Einsatz von LLMs verschiedener Anbieter, die auf grafische Inhalte spezialisiert sind

1

Segmentierung grafischer Inhalte

Segmentierung komplexer Grafiken:

- Zerlegung umfangreicher und detailreicher Abbildungen in kleinere, **weniger komplexe** Einheiten

Verbesserte Interpretierbarkeit:

- Erhöhung der Output Qualität durch vereinfachten **Extraktionsprozess** für das **LLM**

2

Manuelle Daten Integration

Integration zusätzlicher Daten:

- Einbindung zusätzlicher relevanter **Daten** in Form eines **Textdokumentes**

Nachträgliche Inhaltsergänzung:

- Bereitstellung zuvor **nicht** oder nur **unzureichend extrahierten** Informationen


3

Implementierung Aufwand

Einschränkungen bei der Interpretation grafischer Inhalte (2/3)

Ergebnis: Einsatz alternativer LLMs

Benchmark LLM Performance



Vergleich unter identischen Rahmenbedingungen:

- Alle **LLMs** wurden mit denselben Eingabedaten, Prompts und Bewertungskriterien evaluiert

Beste Gesamtpformance von Gemini 3 Pro:

- **Gemini 3 Pro** erzielt Bestwerte bei der **Identifikation** von Hauptprozessen und Unterkategorien

Leistungsunterschiede zwischen LLMs:

- **Gemini 3 Pro** insgesamt beste Performance
- **Gemini 2.3 Pro**, **Claude 4.5** und **GPT-5** leicht darunter, in einzelnen Kategorien jedoch Gleichstand

Deutliche schwächere Performance von GPT-4:

- **GPT-4** Performance liegt in beiden Bewertungskriterien klar unter den übrigen **LLMs**

Einschränkungen bei der Interpretation grafischer Inhalte (2/3)

Ergebnisse: Vorverarbeitung grafischer Inhalte | Manuelle Daten Integration

Segmentierung grafischer Inhalte

Verbesserte Interpretationsqualität:

- Präzisere und vollständigere LLM-Outputs komplexer grafischer Inhalte durch Segmentierung

Modellunabhängiger Performancegewinn:

- Auch **leistungsschwächere LLMs** erzielen durch Segmentierung bessere Ergebnisse als leistungsfähigere LLMs ohne Segmentierung

Reduzierte Halluzinationen:

- Signifikante geringere Fehlinterpretation bei Beziehungen, Abkürzungen und Zeichen

Erhöhter Vorverarbeitungsaufwand:

- Zusätzliche Schritte zur Segmentierung und gezielten Einspeisung der Grafiken in das Modell notwendig

2

Manuelle Daten Integration

Erweiterte Informationsabdeckung:

- Die manuelle Integration von Daten **führte** zu einer signifikanten **Erweiterung der Wissensbasis** des Modells

- unstrukturierte Daten
- simulierte strukturierten Daten

Verbesserter Modelloutput:


- Zuvor **fehlerhafte** oder **nicht ableitbare** Fragestellungen konnten vom Modell korrekt beantwortet werden

3

Qualitative Evaluation (3)

Ergebnisse: Open Beta Modell

Rating Frequency by Evaluation Criteria



Teilnehmer und Umfang:

- 10 Teilnehmende Supply Chain Experten
- 85 Bewertete Einträge

Bewertungskriterien:

- Ø Accuracy: **3.9 / 5**
- Ø Satisfaction: **3.7 / 5**

Reaktionszeit Modell:

- Ø Reaktionszeit **7.8 Sekunden**
- keine Antwortausfälle (Verfügbarkeit)


Frequenz der Bewertungen:

- **Accuracy 5/5** (32 Bewertungen)
- **4/5** (60 Bewertungen)

Qualitative Evaluation (3)

Ergebnisse: Open Beta Modell

Rating Distribution by Evaluation Criteria



Medianwerte:

- Medianwert **Accuracy** 4.0
- Medianwert **Satisfaction**: 4.1
- Insgesamt positive und konsistente Bewertungen

Verteilung der Bewertungen:

- Die Interquartilsbereich **Accuracy**: 3,36 – 4,46
- Die Interquartilsbereich **Satisfaction** 3,42 – 4.40

Identifikation Ausreisser:

- Negativer Ausreisser **Accuracy**: 2.9
- Negativer Ausreisser **Satisfaction**: 2.5
- Beide Ausreisser: gleiche Testperson

Ursache des Ausreissers:

- Hohes Erwartungsniveau Testperson
- Variierende Prompting-Kompetenzen

Qualitative Evaluation (3)

Konsolidierung Ergebnisse Open Beta Modell

Inhalte und Datenumfang

Integration zusätzlicher Datenquellen:

- **Erwartungen** an weitere **relevante Datenquellen**, sowie Hinweise auf nützliche **Zusatzdokumente**

Sensiblen Daten:

- Hinweise zu **sensiblen Dokumenten**, die vom Modell **nicht** verarbeitet oder gespeichert werden sollten

Relevanz vorhandeneren Daten:

- Kritische **Anmerkungen** bezüglich **Relevanz verwendeter Dokumente** für Beantwortung von Fragen

Nutzerpräferenzen und Antwortstil

Output-Darstellung:

- Individuelle **Struktur- und Detailierungspräferenzen** einzelner Teilnehmern

Antwortstil:

- Gewünschte Use-Case-abhängige **Antwortstills** des Modell outputs

Funktionale Erweiterungen & Benutzerfreundlichkeit

Zusätzliche Funktionen:

- **Vorschläge** zur Integration zusätzlicher **Funktionen** und **Erweiterungen**:
 - Hyperlinks
 - Screenshots
 - Exportfunktionen
 - Quellen- und Referenzangaben

Forschungsfrage 1

Zusammenfassung Resultate (1-3)

Integration unstrukturierter Supply Chain Daten

Skalierbare Verarbeitung:

- **Parallelisierung** mittels **Threading** und Batchverarbeitung oftmals **notwendig**

Modulare Integration Daten:

- **Separate Pipelines (Flows)** für Integration und Weiterverarbeitung separater **Datenquellen** für Modell **Skalierung** empfehlenswert
- Mehr Flexibilität
- Individuelles Testing

1

Umgang mit Einschränkungen bei Grafischen Inhalten

LLM-Vergleich:

- **Gemini 3 Pro** erwies sich als das leistungstärkste **LLM**

Lösungsansatz Segmentierung:

- **Segmentierung** komplexer Grafischen Inhalten äusserst **effektiver** Lösungsansatz

Leistungs- / Aufwandsabwägung:

- Bessere Ergebnisse erfordern häufig **zusätzlichen** manuellen oder technischen Aufwand

2

Evaluation der Modelloutputs

Quantitative Evaluation:

- Metriken für die **Quantitativen Evaluation** von Modelloutputs nur beschränkt geeignet
- Metriken bewerten **Textähnlichkeit**, nicht **faktische Korrektheit**

Qualitative Evaluation

- Strukturierte **qualitative Evaluationen (Fragebogen)** liefern wertvolle Hinweise für Modelloptimierungen

3



Forschungsfrage 2

Forschungsfrage 2

Analyse Forschungsfrage

How can GenAI-based automation tools be developed within a development and collaboration platform like Dataiku to scale up by integrating diverse structured supply chain data streams and subsequently unify them via Python-based processing scripts, while applying prompt-engineered SQL generation to enable efficient retrieval and analysis of structured supply chain data?

- Nutzung einer kollaborativen Entwicklungsplattform wie „Dataiku“ (1)
- Skalierung und Integration strukturierter Supply Chain Daten (2)
- Anwendung angepasster Prompts zur Generierung von SQL-Abfragen (Structured Query Language) für eine effizientere Datenintegration (3)

Forschungsfrage 2

Zusammenfassung Resultate

Kollaborative Entwicklungsumgebung

- **Dataiku** ermöglicht **kollaborative** Entwicklung durch **gemeinsame Workflows** und eine **zentrale Plattform**
 - Supply Chain Team
 - Data Science Team
- **Dataiku** fördert **agile, iterative Entwicklung**
- Unterstützt **Skalierung** und **Testing** von GenAI **Modellen**

1

Skalierbare Integration strukturierter Daten

Optimierung Datensatzgrösse:

- Erforderlich bei grossen strukturierten Datensätzen (z. B. SAP), um **Integrations- und Ladezeiten** zu reduzieren
 - 52 Spalten, 1'846'639 Zeilen (5GB)
 - Ladezeit: ~ 2 Min 53 Sek

Selektive Spaltenreduktion:

- bietet Schnelle Performance-**Optimierung** zur Verbesserung der **Integrationszeiten- und Ladezeiten**

2

Prompt-basierte SQL-Abfragen

Effiziente Datenabfrage:

- Ableitung gezielter **SQL-Abfragen** aus Nutzeranfragen über eine angepasste **Prompt-Sektion**
- **Indirekte** Generierung und Ausführung der **SQL-Abfragen** mittels **Python-Code** zur Reduktion des Datenvolumens
 - ⇒ Selektive Datenintegration
 - ⇒ verkürzte Integration und Ladezeit

3

MSD

Umstellung LLM + Segmentierung Ansatz:

- Segmentierung komplexer Grafiken unter **standardmässiger** Nutzung von **Gemini 3 Pro**

Integration zusätzlicher Datenquellen:

- Derzeit **fünf** unstrukturierte **Datenquellen** integriert; Einbindung weiterer sollte geprüft werden

Qualitative Evaluation Methodik:

- Nutzung der etablierten Methodik zur qualitativen Evaluierung **zukünftiger** entwickelten Modelle

Automatisierte Updates & Monitoring:

- Zeitbasierte **automatische Aktualisierungen** der Datenbasis und **Monitoring** der entwickelten Modelle

Klare Verantwortlichkeiten klären:

- Festlegung von Verantwortlichkeiten für den langfristigen **Betrieb** und **Wartung** der Modelle

Research

Reifegrad und Unternehmensgrösse:

- **Analyse** des Zusammenhangs zwischen **Unternehmensgrösse** und **Reifegrad** der entwickelten AI-Tools

GenAI-Adoption

- Indikatoren für eine hohe **Adoptionsrate** sind **Nutzungszufriedenheit**, aktive **Führungskraftunterstützung** und klare **Lernstrukturen**
- Wie können diese **Indikatoren** bestmöglich genutzt werden ?



Ende Präsentation:

Besten Dank für ihre Aufmerksamkeit !



Back Up Slides

Ausgewählte Referenzen

(1/2)

Amazon. (2025). *Was sind strukturierte Daten? Strukturierte Daten erklärt* – AWS.

Amazon Web Services, Inc. <https://aws.amazon.com/de/what-is/structured-data/>

Appini, S. (2025, November 7). *How to Choose the Right LLM for Your Projects: A Guide to Effective Model Benchmarking*. freeCodeCamp.Org.

<https://www.freecodecamp.org/news/choose-the-right-llm-for-your-projects-benchmarking-guide/>

Caballar Diane, R., & Stryker, C. (2024, June 25). *Was sind LLM-Benchmarks? | IBM*.

IBM. <https://www.ibm.com/de/think/topics/llm-benchmarks>

Databricks. (2024, May 30). *A Compact Guide to Retrieval Augmented Generation (RAG)*. Databricks.

<https://www.databricks.com/resources/ebook/train-llms-your-data>

IBM. (2025a, February 7). *Structured vs. Unstructured Data: What's the Difference? | IBM*.

<https://www.ibm.com/think/topics/structured-vs-unstructured-data>

Lovich, D., Bedard, J., Kropp, M., & Taylor, C. (2025, August 5). *GenAI Adoption Is Hard. Radical Employee Centricity Can Help*. BCG Global. <https://www.bcg.com/publications/2025/genai-employee-experience- transformation>

Ausgewählte Referenzen (2/2)

Meade Cleti, & Jano, P. (2024). *Hallucinations in LLMs: Types, Causes, and Approaches for Enhanced Reliability*.
<https://doi.org/10.13140/RG.2.2.12184.61445>

Python. (2025b, December 15). *threading*—Thread-based parallelism. Python Documentation.
<https://docs.python.org/3/library/threading.html>

Rojo-Echeburúa, A. (2025, November 7). *LLM Leaderboard: Which LLMs are Best for Which Tasks?*
<https://www.stack-ai.com/blog/llm-leaderboard-which-llms-are-best-for-which-tasks>


Rosidi, N. (2023, September 6). *Python Threading Like a Pro*.
<https://www.stratascratch.com/blog/python-threading-like-a-pro/>

Vellum. (2025, November 25). *LLM Leaderboard 2025*. Vellum. <https://www.vellum.ai/llm-leaderboard>

Waja, G., Shah, J., & Nanavati, P. (2021). AGILE SOFTWARE DEVELOPMENT. *International Journal of Engineering Applied Sciences and Technology*, 5(12). <https://doi.org/10.33564/IJEAST.2021.v05i12.011>


Knowledge Management System

Grundprinzip




Data GPTeal

Grundprinzip



Methodik

Iterative Modellentwicklung



Quantitative Metriken

BLEU | ROUGE Scores

$$BLEU = BP \times \exp\left(\sum_{n=1}^N \omega_n \log p_n\right)$$

BP = Brevity Output

ω_n = weights of the n-gramm precisions (usually evenly distributed)

p_n = precision of the respective n-gram level

$$ROUGE - N = \frac{\text{Number of matching } n - \text{grams}}{\text{Total } n - \text{grams in the reference}}$$

n-gramm = sequence of n consecutive words



Live Demo Open Beta